



ALF

Expressions régulière et Lexer

Bibliographie pour aujourd'hui



Keith Cooper, Linda Torczon, Engineering a Compiler

- Chapitre 2
 - 2.4
 - 2.5
 - 2.6

Alfred V. Aho, Monica S. Lam, Ravi Sethi, Jeffrey D. Ullman, Compilers: Principles, Techniques, and Tools (2nd Edition)

- Chapitre 3
 - 3.1
 - 3.3

Terence Parr, The Definitive ANTLR 4 Reference, (2nd Edition)

Contenu



- Expressions régulières
- Lexer
- ANTLR



Donald Knuth





- Américain
- TeX
- The Art of Computer Programming
- Stanford

Expressions régulières



- Une façon de décrire la forme d'une string
- Les string sont reconnaissables par un automate fini
- Une string avec des caractères spéciaux

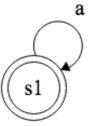
Syntaxe d'expression régulière



Character	Description	Exemple	String
*	Zéro ou plusieurs fois	a*, (ab)*	aaaaaaaa, ababababab
+	Une ou plusieurs fois	a+, (ab)+	aaaaaaa, ababababab
?	Zéro ou une fois	a?, (ab)?	a, ab
٨	début de string	^ab*	abbbbbbb
\$	fin de string	b*a\$	bbbba
•	tout symbole		a, b, c
[]	Ensemble	[abc]	a, b
\ s	Espace blanc	a\sb	a b
[^]	ensemble complémentaire	[^abc]	e, d
()	groupe	(abc)+	Abcabcabc
1	Ou	a b, (ab) (ba)	a, ab

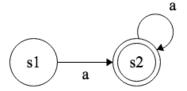
Automate fini pur a*





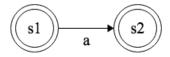
Automate fini pur a+





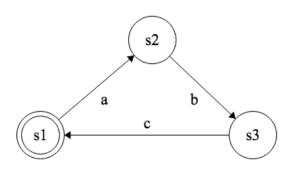
Automate fini pur a?





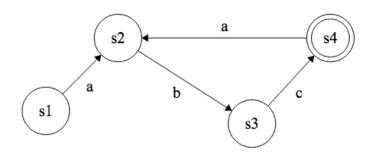
Automate fini pour (abc)*





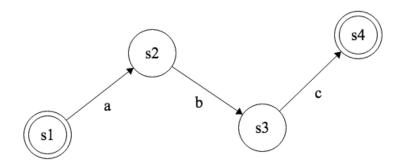
Automate fini pour (abc)+





Automate fini pour (abc)?





Exemples



- Groupe
- Téléphone
- Email
- Nom de variable
- Numéro entier
- Numéro avec virgule

JavaScript RegEx



```
var regex = new RegEx ('...');
var regex = /.../;
```

Documentation

https://developer.mozilla.org/en/docs/Web/JavaScript/Guide/Regular_Expressions

Fonctions

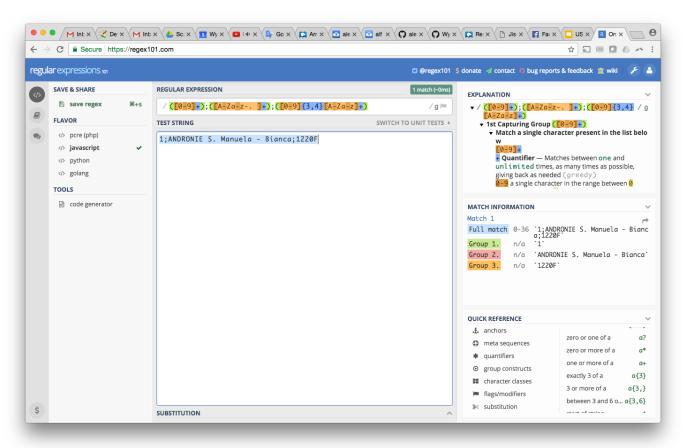


- RegEx
 - regex.exec (string)
 - Array
 - regex.test (string)
 - Boolean
- String
 - str.match (regex)
 - Array
 - str.search (regex)
 - Index of match

RegEx101



https://regex101.com (vérificateur de regex)



Syntaxe d'expression régulière (JS)



Character	Description	Exemple	String
{n}	n fois	a{3}	aaa
{n,m}	au moins n, au plus m	a{3,7}	aaa, aaaa
\w	alphanumérique et _	\w	a, ab
\t	TAB	^a\ta*	a »TAB »a
\n	fin de linge	a\nb	a b
\r	retour chariot	a\rb	a\rb
a(?!b)	a seulement si non suivi par b	a(?!b)	a, aa
a(?=b)	a seulement si suivi par b	a(?=b)	ab
()	group	a(ab)a	aaba

JavaScript Example



```
var regex = new RegEx ('([0-9]+);([A-Za-z-).
]+);([0-9]{3,4}[A-Za-z]+)');
 var regex = /([0-9]+);([A-Za-z-\.]+);([0-9]{3,4}[A-Za-z-\.]+);([0-9]{3,4}[A-Za-z-\.]+);([0-9]{3,4}[A-Za-z-\.]+);([0-9]{3,4}[A-Za-z-\.]+);([0-9]{3,4}[A-Za-z-\.]+);([0-9]{3,4}[A-Za-z-\.]+);([0-9]{3,4}[A-Za-z-\.]+);([0-9]{3,4}[A-Za-z-\.]+);([0-9]{3,4}[A-Za-z-\.]+);([0-9]{3,4}[A-Za-z-\.]+);([0-9]{3,4}[A-Za-z-\.]+);([0-9]{3,4}[A-Za-z-\.]+);([0-9]{3,4}[A-Za-z-\.]+);([0-9]{3,4}[A-Za-z-\.]+);([0-9]{3,4}[A-Za-z-\.]+);([0-9]{3,4}[A-Za-z-\.]+);([0-9]{3,4}[A-Za-z-\.]+);([0-9]{3,4}[A-Za-z-\.]+);([0-9]{3,4}[A-Za-z-\.]+);([0-9]{3,4}[A-Za-z-\.]+);([0-9]{3,4}[A-Za-z-\.]+);([0-9]{3,4}[A-Za-z-\.]+);([0-9]{3,4}[A-Za-z-\.]+);([0-9]{3,4}[A-Za-z-\.]+);([0-9]{3,4}[A-Za-z-\.]+);([0-9]{3,4}[A-Za-z-\.]+);([0-9]{3,4}[A-Za-z-\.]+);([0-9]{3,4}[A-Za-z-\.]+);([0-9]{3,4}[A-Za-z-\.]+);([0-9]{3,4}[A-Za-z-\.]+);([0-9]{3,4}[A-Za-z-\.]+);([0-9]{3,4}[A-Za-z-\.]+);([0-9]{3,4}[A-Za-z-\.]+);([0-9]{3,4}[A-Za-z-\.]+);([0-9]{3,4}[A-Za-z-\.]+);([0-9]{3,4}[A-Za-z-\.]+);([0-9]{3,4}[A-Za-z-\.]+);([0-9]{3,4}[A-Za-z-\.]+);([0-9]{3,4}[A-Za-z-\.]+);([0-9]{3,4}[A-Za-z-\.]+);([0-9]{3,4}[A-Za-z-\.]+);([0-9]{3,4}[A-Za-z-\.]+);([0-9]{3,4}[A-Za-z-\.]+);([0-9]{3,4}[A-Za-z-\.]+);([0-9]{3,4}[A-Za-z-\.]+);([0-9]{3,4}[A-Za-z-\.]+);([0-9]{3,4}[A-Za-z-\.]+);([0-9]{3,4}[A-Za-z-\.]+);([0-9]{3,4}[A-Za-z-\.]+);([0-9]{3,4}[A-Za-z-\.]+);([0-9]{3,4}[A-Za-z-\.]+);([0-9]{3,4}[A-Za-z-\.]+);([0-9]{3,4}[A-Za-z-\.]+);([0-9]{3,4}[A-Za-z-\.]+);([0-9]{3,4}[A-Za-z-\.]+);([0-9]{3,4}[A-Za-z-\.]+);([0-9]{3,4}[A-Za-z-\.]+);([0-9]{3,4}[A-Za-z-\.]+);([0-9]{3,4}[A-Za-z-\.]+);([0-9]{3,4}[A-Za-z-\.]+);([0-9]{3,4}[A-Za-z-\.]+);([0-9]{3,4}[A-Za-z-\.]+);([0-9]{3,4}[A-Za-z-\.]+);([0-9]{3,4}[A-Za-z-\.]+);([0-9]{3,4}[A-Za-z-\.]+);([0-9]{3,4}[A-Za-z-\.]+);([0-9]{3,4}[A-Za-z-\.]+);([0-9]{3,4}[A-Za-z-\.]+);([0-9]{3,4}[A-Za-z-\.]+);([0-9]{3,4}[A-Za-z-\.]+);([0-9]{3,4}[A-Za-z-\.]+);([0-9]{3,4}[A-Za-z-\.]+);([0-9]{3,4}[A-Za-z-\.]+);([0-9]{3,4}[A-Za-z-\.]+);([0-9]{3,4}[A-Za-z-\.]+);([0-9]{3,4}[A-Za-z-\.]+);([0-9]{3,4}[A-Za-z-\.]+);([0-9]{3,4}[A-Za-z-\.]+);([0-9]{3,4}[A-Za-z-\.]+);([0-9]{3,4}[A-Za-z-\.]+);([0-9][
Za-z]+)/;
 var match = regex.exec ('1;ANDRONIE S.
  Manuela - Bianca;1220F';
```



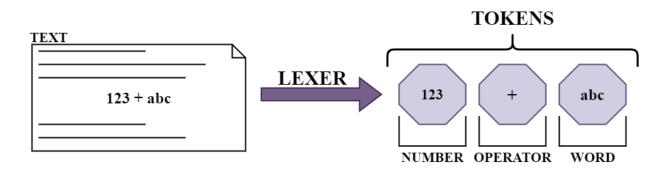
```
([0-9]+);([A-Za-z-\.]+);([0-9]{3,4}[A-Za-z]+)
```

match:

```
['1;ANDRONIE S. Manuela - Bianca;1220F',
'1',
'ANDRONIE S. Manuela - Bianca',
'1220F',
index: 0,
input: '1;ANDRONIE S. Manuela - Bianca;1220F fdsfs' ]
```

Lexer



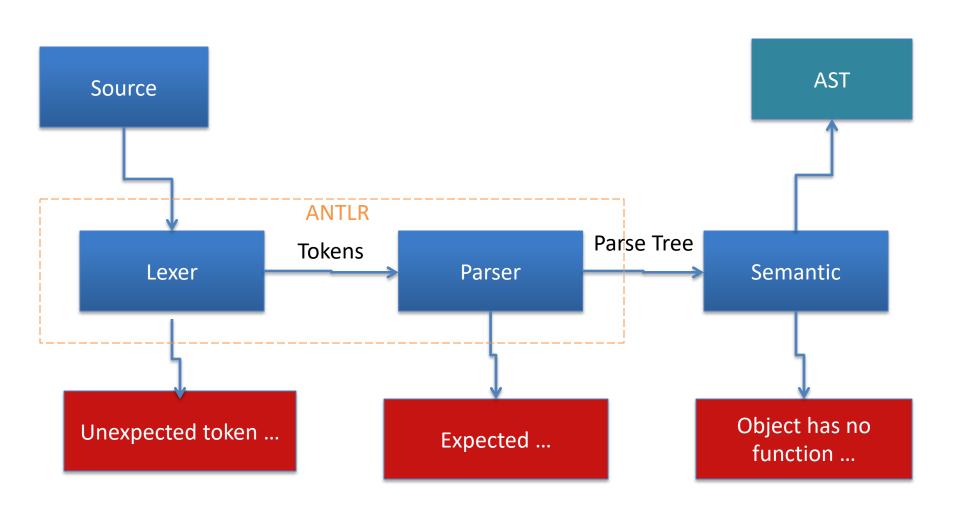






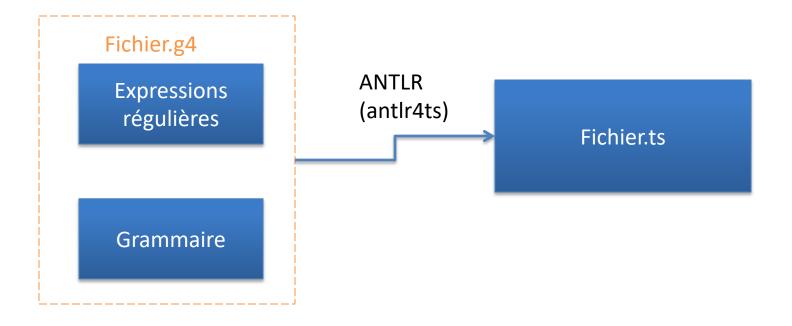
Frontent





Générateur de lexer/parseur





Fichiers G4



- Lexer
 - Expressions réguliers

- Parser
 - Grammaire

Fichier.l (lex ou flex)



```
grammar Expr;
NEWLINE : [\r\n]+ ;
INT : [0-9]+;
prog: (expr NEWLINE)*;
expr: expr ('*'|'/') expr
     | expr ('+'|'-') expr
      INT
      | '(' expr ')'
```

Fichier.g4



```
grammar Expr;
```

Nom

```
NEWLINE : [\r\n]+ ;
INT : [0-9]+ ; Expressions Régulières
```

Nom



grammar Expr;	Nom
	Expression Régulières
	Règles de Grammaire

Expressions Régulières



Règles de Grammaire

```
NEWLINE: [\r\n]+;
INT: [0-9]+;
Expressions Régulières
```

Règles de Grammaire



Nom

Expressions Régulières

Expr.g4 (vide)



```
grammar Expr;
prog: ;
```

Sujets



- Expressions régulières
 - Mathématique
 - JavaScript
- Lexer
- ANTLR

Questions



